

유지우, 하서영, 김주혜, 손가영

신용카드 고객 연체 예측을 위한 데이터 시각화 분석

빅데이터 시각화

목차

연구 배경 및 필요성

- 전통적 신용평가 모형의 한계
- 기계학습 모델의 '블랙박스' 문제
- 설명 가능한 의사결정 지원 시스템의 필요성

연구 목적 및 가설

- Random Forest 알고리즘을 통한 연체 예측 모델 구축
- SHAP과 LIME 기법을 적용한 모델 해석
- 핵심 변수 영향력 및 투명성 확보 검증

데이터 소개

- UCI Machine Learning Repository 데이터셋
- 대만 신용카드 고객 30,000건
- 목표변수: 연체 여부(Target)

데이터 전처리


- 청구 금액 음수(-) 데이터 제외
- 범주형 변수(EDUCATION, MARRIAGE) 정제
- 상환 상태(PAY_0~PAY_6) 변수 통일

탐색적 데이터 분석

- 목표 변수 분포 분석
- 수치형/범주형 변수와 연체율 관계
- 변수 간 상관관계 분석

모델링 및 결과 분석

- Random Forest 모델 성능 평가
- SHAP/LIME을 통한 전역적/국소적 해석
- 개별 고객 리스크 분석 및 연구 결론



연구 배경 및 필요성

신용카드 연체 예측의 중요성과 기존 모델의 한계

- 전통적 신용평가 모형(CSS)은 통계적 기법에 의존하여 해석력은 높으나 비선형적 금융 데이터 패턴 포착에 한계 존재
 - 기계학습 기반 예측 모델은 높은 성능을 보이거나 '블랙박스(Black-box)' 문제로 실무 적용에 어려움 발생
 - 예측 근거를 설명할 수 있는 의사결정 지원 시스템 필요성 증대
- 

신용카드 연체 예측의 중요성과 기존 모델의 한계

- Random Forest 알고리즘을 통한 연체 가능성 예측 모델 구축
 - SHAP과 LIME 기법을 적용한 모델 해석
 - 핀테크 플랫폼의 선제적 리스크 관리를 위한 설명 가능한 의사결정 지원 시스템 제안
- 

연구 가설

가설 1

최근 상환 상태(PAY_0)와 신용한도(LIMIT_BAL)는 신용카드 연체(default) 발생 여부에 가장 큰 영향을 미치는 핵심 변수일 것이다. 이러한 가설은 상관분석과 SHAP 기반 변수 중요도 분석을 통해 검증한다.

가설 2

Random Forest 기반 예측 모델에 SHAP·LIME과 같은 XAI 기법을 적용하면, 높은 예측 정확도를 유지함과 동시에 개별 고객의 연체 위험 판단 근거를 시각적으로 제시할 수 있을 것이다. 이러한 가설은 분류 성능 지표와 모델 해석 결과를 통해 검증한다.

데이터 소개

신용카드 고객 연체 데이터셋


데이터 출처: UCI Machine Learning Repository

데이터 규모: 총 30,000건의 대만 신용카드 고객 데이터

목표 변수: 연체 여부(Target) - 다음 달 연체 발생 여부

주요 변수: 신용한도(LIMIT_BAL), 인구통계학적 정보(성별, 교육, 결혼여부, 나이),
과거 상환 이력(PAY_0~PAY_6), 청구 금액(BILL_AMT1~6), 지불 금액(PAY_AMT1~6)

클래스 불균형: 비연체(77.5%) vs 연체(22.5%)



데이터 전처리

1. 청구 금액 데이터 정제

- 청구 금액(BILL_AMT)이 음수(-)인 논리적 오류가 포함된 데이터 식별
- 해당 고객군을 분석 대상에서 제외하여 데이터 정합성 확보

2. 범주형 변수 정제

- EDUCATION(교육수준) 변수의 '기타' 및 '불명' 항목을 단일 범주로 통합
- MARRIAGE(결혼여부) 변수에서 데이터 수가 극히 적은 '0' 그룹 제거

3. 상환 상태 변수 통일

- 상환 상태(PAY_0~PAY_6) 변수 내의 '-2'와 '-1' 값은 모두 '정상 납부'를 의미
- 이를 '-1'로 통일하여 변수의 차원을 축소하고 해석의 용이성 확보



탐색적 데이터 분석(EDA)

수치형 변수 분석: 신용한도(LIMIT_BAL): 낮을수록 연체율이 크게 증가→ 강한 반비례 관계
연령(AGE): 연체·비연체 간 차이 거의 없음→ 예측력 낮음

범주형 변수 분석: 교육(Education): 고등학교 졸업 그룹이 연체율 가장 높고, 대학원 졸업 그룹이 가장 낮음
결혼(Marriage): '기타(3)' 그룹의 연체율이 높게 나타남→ 의미 있는 패턴 존재
청구금액(BILL_AMT), 지불금액(PAY_AMT): 일정한 연체 패턴 없음→ 단독 변수로는 제한적

목표 변수와 가장 높은 상관계수를 보인 변수는 **PAY_0 (상환 상태)**
→ 상관계수 약 **0.32**로 연체 예측의 가장 중요한 선행 지표


수치형 변수와 연체율 관계 시각화



신용한도(LIMIT_BAL)는 연체율과 뚜렷한 반비례 관계를
보였으나, 청구금액(BILL_AMT)은 연체 여부와 큰 차이가 없음


저한도 구간 연체율 32.2%, 고한도 구간 14.3% → 신용한도는 연체와 강하게 연결됨

목표 변수 분포 - 연체/비연체 비율 확인



연체 여부(target)는 ‘비연체(0)’가 다수이며 연체(1)은 소수인 클래스 불균형 데이터 구조 양상

목표 변수 분포 - 연체/비연체 비율 확인



성별과 연체율 차이


X축: 성별

Y축: 연체율(0~1)

구분: 남성(0), 여성(1)

남성(0)이 여성(1)보다 연체율이 약간 높게 나옴

목표 변수 분포 - 연체/비연체 비율 확인



학력 수준과 연체율 차이

X축: 학력 수준


Y축: 연체율

구분: 대학원(1), 대졸(2), 고졸(3), 기타(4)

Education=2(대졸) 그룹의 연체율이 가장 높음

(그래프 상 고졸(3)이 가장 높지만, 표본이 적음)

수치형 변수별 연체율 계산(고급 분석)



신용한도 구간별 연체율


신용한도가 낮을수록 연체율이 매우 높고,
신용한도가 높아질수록 연체율은 꾸준히 감소 (반비례 관계)

구간별 연체율 차이가 뚜렷해 LIMIT_BAL은 연체 예측 모델에서
매우 강한 예측 변수로 해석 가능

금융시장 관점에서의 신용한도(LIMIT_BAL) 변수 활용 의미:

- 한도 정책이 고객 위험을 효과적으로 구분하고 있음을 보여줌
- 한도가 낮은 고객군을 조기 리스크 관리 대상으로 설정할 수 있다는 시사점 제시

수치형 변수별 연체율 계산(고급 분석)



연령 구간별 연체율


AGE(나이)는 구간에 따라서 다른 경향을 나타내고
모든 연령대에서 연체율이 비슷하게 나타남

나이는 연체 여부를 구분하거나 예측하는 주요 변수로 보기 어려움

금융시장 관점에서 나이 변수 활용의 한계:

- 나이만으로 위험을 단독 판단하기에는 한계 존재
- 생애주기 기반 금융 리스크 분석에서 보조 지표로 활용 가능
- 청년층 vs 중·장년층의 리스크 관리 전략 차별화에 중요한 기준점 제공

수치형 변수별 연체율 계산(고급 분석)



연체 여부에 따른 월별 청구금액 분포 비교


- BILL_AMT1~6의 구간별 연체율은 월별·구간별로 큰 차이가 없음
- 모든 구간에서 연체율은 약 평균 20% 내외로 안정적으로 유지

BILL_AMT(월별 청구금액)는 연체 여부를 판별하는 주요 변수로 보기 어려움

금융시장 관점에서 청구금액(BILL_AMT) 변수 활용의 한계:

- 부채 규모가 크다고 해서 반드시 연체가 발생하는 것은 아님
- 핵심 변수는 부채의 크기보다 현재의 상환 능력
- 리스크 평가는 총부채보다 상환 여력 중심으로 접근해야 함

수치형 변수별 연체율 계산(고급 분석)



상환금액(PAY_AMT1~6)과 연체 여부의 관계


- PAY_AMT1~6 모두 지불금액이 높을수록 연체율이 낮아지는 명확한 경향을 보임
- 가장 낮은 지불금액 구간의 연체율이 가장 높고, 가장 높은 지불금액 구간의 연체율이 가장 낮음

PAY_AMT는 연체와 직접 관련이 있는 핵심 신용 위험 지표로 해석 가능

금융시장 관점에서 상환금액(PAY_AMT) 변수 활용의 의미:

- 고객의 현재 상환 능력을 직접적으로 반영하는 즉각적 위험 신호
- 지불금액 감소 고객을 조기에 파악하여 선제적 연체 예방 가능
- 금융기관의 리스크 모니터링 지표로 활용 가치 높음


수치형 변수 간 상관관계 히트맵



PAY_0(상환 상태)는 연체 여부와 가장 높은 양의 상관을 보이는 주요 예측 변수


EDA로 알 수 있는 패턴

**신용한도와
연체율**




계단식 하락 패턴

나이와 연체율



L자형 패턴

**상환금액과
연체율**



U자형 패턴

RandomForest를 활용한 예측 모델

--- 📊 모델 평가 결과 ---

1. 전체 정확도 (Accuracy): 0.7960


2. 혼동 행렬 (Confusion Matrix):

```
[[1791  154]
 [ 367  242]]
```

3. 상세 보고서 (Classification Report):

	precision	recall	f1-score	support
정상(0)	0.83	0.92	0.87	1945
불이행(1)	0.61	0.40	0.48	609
accuracy			0.80	2554
macro avg	0.72	0.66	0.68	2554
weighted avg	0.78	0.80	0.78	2554

개별 고객 위험도 분석 (SHAP Waterfall Plot, LIME)




낮은 신용한도(LIMIT_BAL=50,000)와 과거 연체 이력이 복합적으로 작용하여 연체 확률이 기저 확률(Base Value)보다 크게 상승

→ 높은 성능을 유지하면서도 의사결정의 투명성과 설명 가능성이 확보되었음을 입증

→ 가설 2 뒷받침

모델의 전역적 해석 (SHAP Summary Plot)



PAY_0는 연체 확률을 가장 크게 높이는 변수,
LIMIT_BAL은 연체 위험을 낮추는 방향으로 작용하는 변수

→ 최근 상환 이력과 신용 능력이 핵심 결정 요인임을 보여줌

→ 가설 1 뒷받침

최종 정리

1. 신용은 '스펙'이 아닌 행동이 결정

최근 상환 행동(PAY_0·BILL_AMT 등)이 나이·성별·학력보다 훨씬 강력한 예측 변수임을 확인

2. 3040세대는 금융기관의 최우량 고객

U자형 연체율 패턴 분석을 통해, 안정적 상환 능력과 높은 신용 유지 의지를 가진 핵심 타깃층임을 도출

3. 금융에서 XAI는 선택이 아니라 생존


설명 가능한 AI는 규제 준수 뿐 아니라 고객 컨설팅 기능을 수행하며, 새로운 영업 도구로 활용 가능

분석 결과를 통한 시사점

Behavior Wins



3040 재발견



XAI 배면 시체



조원 깃허브 주소

20241239하서영

<https://github.com/gktjdud0716-commits/Big-data-visualization>

20241231 손가영

<https://github.com/Gayoung-0315/credit-default-prediction.glt>

20241236 유지우

<https://github.com/juju-kr?tab=repositories>

20241233 김주혜

https://github.com/juhyekimm/credit-default-prediction/blob/main/Credit_Default_Prediction_XAI-2.ipynb4



유지우, 하서영, 김주혜, 손가영

감사합니다

빅데이터 시각화